

Sprawozdanie ze Spectral Tool

**Ćwiczenia 4-5: równowagi i specjacja - pKa, samoasocjacja
i kompleksowanie**

Ćwiczenie 4. Równowagi, specjacja i dopasowanie pKa

Cel ćwiczenia

Celem było wyznaczenie liczby form kwasowo-zasadowych z danych spektrofotometrycznych, oszacowanie udziałów form w funkcji pH i dopasowanie pKa dla układów 3-, 4- i 5-formowych.

Model matematyczny i założenia

Macierz widm potraktowałem jako kombinację liniową widm form czystych ważonych ich udziałami przy danym pH: $A(\lambda, \text{pH}) \approx \sum_i \chi_i(\text{pH}) A_i(\lambda)$, gdzie udziały χ_i są nieujemne i sumują się do 1. Liczbę form oceniałem przez PCA, a potem dopasowywałem udziały i pKa.

Pliki przypisałem następująco: Ledakrin - 3 formy, Symadex - 4 formy, C-2045 - 5 form. pKa wyznaczyłem z funkcji udziałów form i sprawdziłem metodą leave-one-out.



Rys. 1. Udział wariacji pierwszych składowych PCA.

Pierwsze składowe wyjaśniają prawie całą wariację, ale w praktyce o liczbie form decyduje także interpretacja słabszych składowych i geometria punktów w przestrzeni PCA.

Tabela 1. Podsumowanie PCA dla danych spektrofotometrycznych.


plik	liczba form	PC1 [%]	PC2 [%]	PC3 [%]	PC4 [%]	suma wybranych PC [%]
example-Ledakrin.csv	3	83.536	16.420	0.04287	1.64e-04	100.000
example-Symadex.csv	4	94.630	4.4469	0.91802	0.00463	100.000
example-C-2045.csv	5	96.621	2.8110	0.49067	0.05933	99.999

Tabela 2. Dopasowane wartości pKa i wyniki walidacji LOO.

plik	formy	SSE	OK	pKa1	LOO1	SD1	pKa2	LOO2	SD2
Ledakrin	3	0.0769	True	6.2449	6.2449	0.0030	9.3230	9.6142	1.4017
Symadex	4	2.1052	True	2.8058	2.8075	0.0230	7.6289	7.6271	0.0417
C-2045	5	1.2527	True	2.4293	2.4317	0.0237	6.1203	6.1198	0.0083


Ciąg dalszy Tabeli 2: parametry pKa3-pKa4 oraz wyniki LOO-CV dla układów cztero- i pięcioformowych.

plik	pKa3	LOO3	SD3	pKa4	LOO4	SD4
Ledakrin	-	-	-	-	-	-
Symadex	9.6069	9.6094	0.0196	-	-	-
C-2045	7.1587	7.1592	0.0277	9.6282	9.6153	0.1764




Rys. 2. Udziały form dla Ledakrin - model 3-formowy.

Przejścia między formami są opisane przez dwa pK_a . Druga wartość pK_a ma dużą niepewność LOO, co sugeruje słabsze określenie przejścia przy wysokim pH.




Rys. 3. Dopasowanie pK_a dla Ledakrin.

$pK_a = 6.2449$ oraz 9.3230 .




Rys. 4. Udziały form dla Symadex - model 4-formowy.

Trzy wartości pK_a opisują cztery formy; odchylenia LOO są małe, więc rozwiązanie jest stabilniejsze niż dla Ledakrin przy wysokim pH .




Rys. 5. Dopasowanie pK_a dla Symadex.

Dopasowanie ma stabilne pK_a w walidacji LOO, co wskazuje na dobrze rozróżnialne przejścia w danych.



Rys. 6. Udziały form dla C-2045 - model 5-formowy.

Układ 5-formowy jest trudniejszy numerycznie. Udziały form są traktowane jako przybliżenie, ponieważ optymalizacja geometryczna osiągnęła limit iteracji.



Rys. 7. Dopasowanie pKa dla C-2045.

Cztery pKa opisują pięć form; największa niepewność LOO dotyczy ostatniego przejścia przy wysokim pH.

Dyskusja

Dla Ledakrinu dwie pierwsze składowe PCA praktycznie wyczerpują wariancję, co odpowiada układowi 3-formowemu. Dla Symadexu trzecia składowa wciąż coś wnosi, dlatego przyjąłem 4 formy. Dla C-2045 dalsze składowe są już słabe, ale model 5-formowy wynikał z danych i z instrukcji - i to on jest najbardziej podatny na numeryczną niejednoznaczność.

Wartości pKa są parametrami modelu równowagowego, więc ich wiarygodność zależy od tego, jak dobrze formy rozdzielają się w widmach. Najstabilniej zachował się Symadex, gdzie LOO SD dla pKa było małe. W Ledakrinie wysokie LOO SD dla drugiego pKa oznacza, że pojedyncze punkty mocno wpływają na to przejście, a w C-2045 mniej stabilne jest ostatnie pKa - co dla wieloformowych układów z nakładającymi się widmami jest typowe.

Wnioski

1. PCA pozwoliło przypisać dane do układów 3-, 4- i 5-formowych, choć słabe składowe wymagają ostrożności w interpretacji.
2. Dla Ledakrin uzyskałem pKa około 6.245 i 9.323, z dużą niepewnością drugiego przejścia.
3. Dla Symadex wyszły trzy stabilne wartości pKa: około 2.806, 7.629 i 9.607.
4. Dla C-2045 wyszły cztery wartości pKa: około 2.429, 6.120, 7.159 i 9.628, ale model 5-formowy jest numerycznie najbardziej wrażliwy.
5. Walidacja LOO jest istotna, bo pokazuje nie tylko jakość dopasowania, ale i odporność pKa na usunięcie pojedynczych punktów pH.

Odpowiedzi na pytania kontrolne

Liczbę form wybrano na podstawie PCA, geometrii punktów i sensu chemicznego: Ledakrin - 3 formy, Symadex - 4 formy, C-2045 - 5 form. Dla Ledakrinu dwie pierwsze składowe wyjaśniały praktycznie całą wariancję układu 3-formowego. Dla Symadex istotna była jeszcze trzecia składowa, a dla C-2045 konieczny był model 5-formowy z czterema przejściami pKa.

Wykres osypiska PCA nie wskazywał liczby form całkowicie jednoznacznie. Potrzebne były dodatkowe argumenty: przebieg udziałów molowych, stabilność LOO-CV, sens chemiczny kolejnych przejść i geometria punktów PCA. Sam udział wariancji może ukrywać słabe, ale chemicznie istotne składowe.

Udziały molowe zmieniały się zasadniczo sensownie z pH: formy dominowały kolejno w miarę wzrostu pH, a sumy udziałów wynosiły 1. Dla C-2045 interpretacja jest ostrożniejsza, bo układ 5-formowy jest bardziej wrażliwy numerycznie.

Wartości pKa z dopasowania głównego były zgodne z LOO-CV najlepiej dla Symadex: SD LOO wynosiło 0.02298, 0.04167 i 0.01964. Dla C-2045 pierwsze trzy przejścia były stabilne, a największa niepewność dotyczyła pKa4, SD = 0.17641. Dla Ledakrinu pKa2 było niestabilne w LOO, SD = 1.40168.

Najbardziej stabilne dopasowanie dał Symadex, ponieważ wszystkie trzy pKa miały małe odchylenia LOO i logiczne przejścia między czterema formami. Ledakrin miał problem z drugim przejściem, a C-2045 był trudniejszy z powodu pięciu form.

Układ 5-formowy jest trudniejszy od 3-formowego, ponieważ ma więcej wierzchołków simpleksu, więcej granic geometrycznych i więcej pKa. Niewielki błąd w rozdziale widm może przenieść się na kilka sąsiednich udziałów molowych.

Duże odchylenie standardowe pKa w LOO-CV oznacza, że usunięcie jednego punktu pH istotnie zmienia wynik. Parametr nie jest wtedy dobrze zakotwiczony w danych i powinien być interpretowany ostrożnie.

Wartości początkowe pKa mogą wpływać na wynik, ponieważ dopasowanie jest nieliniowe. Funkcja celu może mieć lokalne minima, a przy słabo rozdzielonych formach może dochodzić do zamiany przejść lub niestabilnego przypisania form.

Objawy błędnie dobranej liczby form to: udziały poza zakresem 0-1, brak sumowania do 1, chaotyczne przebiegi, forma pojawiająca się tylko jako szum, brak logicznej kolejności przejść względem pH oraz bardzo duże SD w LOO-CV.

pKa można traktować jako wielkość chemiczną tylko wtedy, gdy model, liczba form, dane i dopasowanie są wiarygodne. W przeciwnym razie pKa jest głównie parametrem matematycznego dopasowania, a nie mocnym dowodem na konkretną równowagę chemiczną.

Pliki wynikowe ćwiczenia 4 obejmują: tabele PCA i pKa, pliki CSV z udziałami form dla Ledakrinu, Symadex i C-2045, wykresy osypiska, udziały form, wykresy pKa oraz raporty tekstowe pKa w katalogu wynikowym.

Ćwiczenie 5. Równowagi i specjacja: samoasocjacja i kompleksowanie

Cel ćwiczenia

Celem była analiza trzech zestawów widm: UV-Vis samoasocjacji makrolidu polienowego, CD samoasocjacji tego samego typu układu oraz UV-Vis kompleksowania DNA przez ligand PU22. W każdym bloku wykonałem preprocessing, PCA, oszacowanie liczby form spektralnych, wyznaczenie udziałów form i dopasowanie modelu równowagowego.

Podstawy teoretyczne i model matematyczny

Widmo mieszaniny opisałem jako kombinację liniową widm form czystych: $A(\lambda, x) \approx \sum_i \chi_i(x) A_i(\lambda)$, gdzie udziały χ_i sumują się do 1 i mieszczą w zakresie 0-1. W blokach samoasocjacji dzieliłem widma przez stężenia z etykiet kolumn, żeby oddzielić zmianę kształtu widma od zwykłego wzrostu ilości liganda.

Dla samoasocjacji sprawdziłem modele monomer-dimer, monomer-tetramer i monomer-agregat izodesmiczny. W dimerze $K_d = [M]^2/[D]$, w tetramerze $K_d = [M]^4/[T]$, a udziały podawałem jako frakcję całkowitego liganda w danej formie.

Kompleksowanie opisałem schematem $D + L \leftrightarrow DL$ oraz $DL + L \leftrightarrow DL_2$. Ponieważ ani instrukcja, ani pliki CSV nie podają fizycznego L_0 ani współczynnika rozcieńczenia, dopasowanie zrobiłem w jednostkach znormalizowanych ($L_0 = 1$, $vol_coeff = 1$). Dlatego K_{dA_model} i K_{dB_model} są efektywnymi, modelowymi parametrami dysocjacji w jednostkach osi eksperymentalnej, a nie bezwzględnymi wartościami w mol/L.

Metodyka obliczeń

Ćwiczenie 5 policzyłem w Pythonie według procedury Spectral Tool z instrukcji: preprocessing widm, normalizacja, PCA, dekompozycja form, dopasowanie modeli samoasocjacji i kompleksowania oraz walidacja LOO-CV. Sens modeli pozostał zgodny z instrukcją.

Schemat zapisu wyników, generowania wykresów i tabel oraz metryki SSE i LOO-CV są te same co we wcześniejszych ćwiczeniach. Specjalnie dla ćwiczenia 5 dopisałem parser danych spektralnych rozdzielanych średnikami, normalizację widm przez stężenie, PCA z dekompozycją liniową i trójkątną oraz modele samoasocjacji i kompleksowania DNA-ligand.

Wykonanie zadań i wyniki

Tabela 3. Wyniki dekompozycji spektralnej w ćwiczeniu 5.

Blok	Dane	Preprocessing i zakres	Formy	PC1 [%]	PC2 [%]	PC3 [%]
I	UV samoasocjacja	podział przez stężenie; 250-450 nm	2	97.02	2.87	0.06
Ila	CD samoasocjacja, pełny zestaw	podział przez stężenie; 250-450 nm	2 do fitu; 3 test	84.04	12.95	1.17
Ilb	CD samoasocjacja, bez pierwszego widma	podział przez stężenie; usunięto pierwsze widmo; 250-450 nm	2 do fitu; 3 test	94.22	3.16	1.42
III	UV kompleksowanie PU22-DNA	okno 360-500 nm; bez podziału przez stężenie	3	99.56	0.38	0.06

UV-Vis samoasocjacji opisano modelem dwustanowym. Dla CD widoczne były silniejsze składowe dodatkowe, dlatego wariant 3-formowy sprawdzono diagnostycznie, ale do stabilnego fitu przyjęto interpretację dwustanową. Dla PU22 użyto trzech form w oknie 360-500 nm.

Tabela 4. Wyniki dopasowania samoasocjacji w ćwiczeniu 5.


Analiza	Role form	Parametry	SSE	LOO-CV SSE	Wniosek
UV	tetramer	0.00539275	0.1856	0.2726	najlepszy wariant
CD, pełny zestaw	tetramer	0.372593	0.0908	0.0965	najlepszy wariant dwustanowy
CD, pełny zestaw	monomer / dimer / tetramer (diagnostycznie)	0.0411966; 0.00167053	2.1791	3.2033	wariant 3-formowy; gorzej stabilny niż 2-formowy
CD, bez pierwszego widma	tetramer	1.37351	0.1333	0.1396	najlepszy wariant dwustanowy
CD, bez pierwszego widma	monomer / dimer / tetramer (diagnostycznie)	0.0460728; 0.00289256	2.1568	3.0340	wariant 3-formowy; gorzej stabilny niż 2-formowy

Najniższe SSE/LOO-CV dla UV i CD dawał wariant monomer-tetramer. Warianty 3-formowe CD miały wyraźnie gorszą stabilność, więc potraktowano je jako diagnostykę, a nie jako mocny dowód na trzy dobrze rozdzielone formy chemiczne.

Tabela 5. Wyniki dopasowania kompleksowania DNA-ligand w ćwiczeniu 5.


Formy chemiczne	Parametry	SSE	LOO-CV SSE	Wniosek
free_ligand / single_bound_ligand / double_bound_ligand	L0=1.0 (znormalizowane); vol=1.0 (brak danych o rozcieńczeniu); KdA_model=0.00509; KdB_model=2.6580	0.07237	0.26224	KdA_model << KdB_model w jednostkach znormalizowanych/modelowych; drugie wiązanie jest słabiej obsadzone w modelu.

Wartości KdA_model i KdB_model są znormalizowanymi/modelowymi parametrami dysocjacji, ponieważ z danych wejściowych nie dało się odtworzyć absolutnego L0 ani korekty rozcieńczenia.




Rys. 8. Widma UV-Vis samoasocjacji po normalizacji przez stężenie.

Po normalizacji zmiany widm są uporządkowane wraz ze stężeniem, co uzasadnia analizę udziałów form zamiast samej absorbancji całkowitej.




Rys. 9. Wykres osypiska PCA dla UV-Vis samoasocjacji.

PC1 i PC2 obejmują łącznie 99.883% wariancji; zgodnie z instrukcją przyjęto model dwustanowy.




Rys. 10. Dopasowanie modelu samoasocjacji do frakcji z widm UV-Vis.

Najlepszy wariant w tej procedurze to model monomer-tetramer, choć wynik należy traktować jako opis zmian spektralnych, a nie bezpośredni dowód strukturalny tetrameru.




Rys. 11. Widma CD po normalizacji przez stężenie - pełny zestaw.

Widma CD są bardziej złożone niż UV-Vis i silniej reagują na uporządkowanie agregatów.




Rys. 12. PCA widm CD dla pełnego zestawu.

PC2 ma udział 12.95%, więc CD sugeruje dodatkową zmienność względem prostego modelu liniowego.




Rys. 13. Dopasowanie samoasocjacji do pełnego zestawu CD.

Dwustanowy model tetramerowy daje najlepszy stabilny fit, natomiast wariant trójformowy był mniej stabilny.




Rys. 14. PCA widm CD po usunięciu pierwszego widma.

Usunięcie pierwszego widma zwiększa udział PC1 z 84.04% do 94.22%, czyli zmniejsza wpływ punktu o niskim sygnale.




Rys. 15. Dopasowanie samoasocjacji do CD po usunięciu pierwszego widma.

Interpretacja pozostaje dwustanowa, ale usunięcie pierwszego widma nie usuwa całkowicie niejednoznaczności CD.




Rys. 16. Widma PU22 w oknie 360-500 nm użytym do analizy kompleksowania.

Zakres zawężono, aby ograniczyć wpływ ogona absorpcji DNA i skupić się na sygnale liganda.



Rys. 17. PCA danych PU22 w oknie 360-500 nm.

Trzy pierwsze składowe obejmują 99.999% wariancji, co wspiera analizę trzech form spektralnych.



Rys. 18. Frakcje form liganda z modelu kompleksowania DNA-ligand.

W modelu znormalizowanym *free_ligand* zanika wraz z dodatkiem DNA, a *single_bound_ligand* dominuje przy większym nadmiarze DNA.

Odpowiedzi na pytania do sprawozdania

Widma UV-Vis samoasocjacji można opisać modelem dwustanowym. Przemawia za tym uporządkowany przebieg widm po normalizacji, zgodność z oczekiwaniem instrukcji oraz PCA: $PC1+PC2 = 99.883\%$ wariancji. W dopasowaniu frakcji najlepszy był wariant monomer-tetramer, $SSE = 0.18564$ i $LOO-CV\ SSE = 0.27260$.

W bloku I formom przypisano role monomer oraz szeroko rozumiana forma zagregowana. Spośród testowanych ról dimer/tetramer/agregat izodesmiczny najniższe $SSE/LOO-CV$ dał model tetramerowy. Nie oznacza to bezpośredniego dowodu strukturalnego tetrameru, tylko najlepszy opis zmian spektralnych wśród sprawdzonych modeli.

Widma CD nie wskazują tak jednoznacznie tej samej liczby form co UV-Vis. W pełnym zestawie CD $PC1 = 84.04\%$, $PC2 = 12.95\%$, a $PC3 = 1.17\%$, czyli zmienność jest bardziej wielowymiarowa. Przyczyną może być większa czułość CD na uporządkowanie przestrzenne agregatów.

Usunięcie pierwszego widma CD zwiększyło udział $PC1$ z 84.04% do 94.22% , więc pierwszy punkt miał duży wpływ na PCA. Liczba form chemicznie interpretowalnych nie zmieniła się jednoznacznie: wariant 3-formowy nadal był diagnostycznie możliwy, ale fit 3-formowy pozostawał niestabilny. Stabilniejsza interpretacja pozostała dwustanowa.

Model samoasocjacji dla CD daje parametry umiarkowanie stabilne tylko w wariancie dwustanowym. Dla pełnego CD najlepszy model tetramerowy miał $SSE = 0.09083$ i $LOO-CV\ SSE = 0.09651$. Wariant 3-formowy monomer/dimer/tetramer miał dużo gorsze $LOO-CV\ SSE = 3.20330$, więc nie jest stabilnym rozwiązaniem.

UV-Vis i CD nie muszą dawać identycznej liczby form, ponieważ mierzą inne cechy układu. UV-Vis jest silnie związany z przejściami elektronowymi i zmianami absorbancji, a CD jest wrażliwy na chiralne uporządkowanie i geometrię agregatów.

W analizie kompleksowania DNA zawężono okno spektralne do 360-500 nm, aby ograniczyć wpływ ogona absorpcji DNA obecnego przy krótszych falach. Bez tego PCA i dopasowanie mogłyby opisywać głównie wkład DNA, a nie zmianę stanu liganda.

Formy kompleksowania przypisano po dominacji w przebiegu miareczkowania: `free_ligand` dominuje przy 0 ekwiwalentach DNA, formy związane pojawiają się po dodaniu DNA, a `single_bound_ligand` dominuje w modelu przy dużym nadmiarze DNA. Kolejności `Form_1/Form_2/Form_3` nie traktowano automatycznie jako kolejności chemicznej.

W dopasowaniu znormalizowanym/modelowym $KdA_model = 0.00509$, a $KdB_model = 2.65802$. Oznacza to różne efektywne powinowactwa dwóch etapów wiązania w tej skali: pierwszy etap jest znacznie silniej obsadzany niż drugi. Ze względu na brak fizycznego $L0$ i `vol_coeff` nie należy podawać tych wartości jako bezwzględnych molowych stałych dysocjacji.

Największe źródła niepewności to arbitralność wyboru liczby form przy słabszych składowych PCA, przypisanie form chemicznych do form spektralnych, brak $L0$ i `vol_coeff` dla kompleksowania oraz wrażliwość CD na pierwszy punkt o niskim stężeniu.

Dyskusja

Ćwiczenie 5 dobrze pokazuje, że sama PCA nie wystarcza do jednoznacznej interpretacji chemicznej. W UV-Vis samoasocjacji wynik jest stosunkowo czysty: po normalizacji widma układają się w uporządkowaną serię i pasują do opisu dwustanowego. W CD jest trudniej, bo dodatkowa zmienność widmowa może oznaczać realne uporządkowanie agregatów, ale równie dobrze może brać się z większego szumu albo silnego wpływu pierwszego widma.

Przy kompleksowaniu DNA największym ograniczeniem jest brak bezwzględnych warunków eksperymentu. Model dobrze oddaje zanik wolnego liganda i narastanie form związanych, ale K_{dA_model} i K_{dB_model} pozostają efektywnymi parametrami modelowymi, a nie bezwzględnymi stałymi w mol/L. Przypisanie form wymagało sprawdzenia, która z nich dominuje bez DNA, przy pośrednich ekwiwalentach i przy nadmiarze DNA.

Wnioski

1. UV-Vis samoasocjacji można rzetelnie opisać modelem dwustanowym; najlepszy z testowanych wariantów odpowiadał roli monomer-tetramer.
2. CD jest bardziej wrażliwe na dodatkowe zmiany spektralne niż UV-Vis, ale wariant trójformowy nie dał stabilnego dopasowania chemicznego.
3. Usunięcie pierwszego widma CD poprawiło strukturę PCA, lecz nie rozwiązało całkowicie problemu interpretacji liczby form.
4. Kompleksowanie PU22 z DNA opisano w oknie 360-500 nm modelem `free_ligand/single_bound_ligand/double_bound_ligand`.
5. Bezwzględnych stałych dysocjacji dla kompleksowania nie można podać bez fizycznego L_0 i vol_coeff ; raportowane K_{dA_model} i K_{dB_model} są znormalizowanymi/modelowymi parametrami dysocjacji.